

Base de Données : Adult (Census Income)

1. Identification générale

Nom : Adult (Census Income)

Source : UCI Machine Learning Repository

Donateur : Barry Becker (30 avril 1996)

Type : Données multivariées, mixtes (numériques et catégorielles)

Objectif : Prédire si le revenu annuel d'un individu dépasse 50 000 \$/an.

2. Taille et caractéristiques des données

Nombre d'instances : 48 842

Nombre de variables : 14 (hors variable cible)

Valeurs manquantes : Oui ('?' dans certaines colonnes)

Format : CSV (séparé par des virgules)

Licence : Creative Commons BY 4.0

3. Description des variables

1. age : Âge de l'individu
 2. workclass : Catégorie d'emploi
 3. fnlwgt : Poids de l'échantillon
 4. education : Niveau d'éducation
 5. education-num : Niveau d'éducation (numérique)
 6. marital-status : Statut marital
 7. occupation : Type d'occupation
 8. relationship : Statut de relation
 9. race : Race
 10. sex : Sexe
 11. capital-gain : Gain en capital
 12. capital-loss : Perte en capital
 13. hours-per-week : Heures travaillées par semaine
 14. native-country : Pays d'origine
- Cible : income (>50K ou ≤50K)

4. Utilisation et contexte

Utilisation : Classification binaire, détection de biais (sexe, race)

Domaines : Apprentissage automatique, équité algorithmique, économie du travail

Limites : Données anciennes (recensement 1994), seuil arbitraire de 50 000 \$, biais démographiques potentiels.

5. Recommandations d'analyse

- Analyse descriptive : distributions, corrélations, visualisations
- Nettoyage : gérer les valeurs manquantes ('?')
- Encodage : one-hot encoding des variables catégorielles
- Modélisation : régression logistique, arbres de décision, forêts aléatoires
- Interprétation : importance des variables, inégalités de revenus

- Communication : rédiger un rapport clair et structuré en français.